rtweet パッケージのあれこレシピ

@anemptyarchive*

2019/11/21-2020/05/25

Contents

・ツイート収集

まずは `rtweet` パッケージを利用して、ツイートを集めます。

```
# 利用パッケージ
library(rtweet)

# アカウントを指定
screen_name <- "anemptyarchive"

# アカウント指定でツイートを収集
tw_data <- get_timeline(screen_name, n = 10000, include_rts = FALSE)
```

`get_timeline()` にアカウント (@*** の ***) を指定して、ツイートを取得します。引数 `n` は収集するツイート数、`include_rts` は取得ツイートにリツイートを含めるかです (デフォルトは TRUE)。

特定の単語を含むツイートを収集するのであれば、`search_tweets("検索ワード")` を使います。

どちらも取得できるツイートの数に制限があったりします。

*https://www.anarchive-beta.com/

・ツイート数を棒グラフで可視化

rtweet パッケージを利用して、指定したアカウントのタイムラインインを収集し、設定した期間 (年・月・日・時) ごとのツイート数を集計し、棒グラフによる可視化を行います。

```
library(rtweet) # ツイート収集:get_timeline(), search_tweets()
library(dplyr) # データフレーム操作
library(lubridate) # 時間データ操作:floor_date(), as_date()
library(ggplot2) # 作図
```

利用するパッケージを読み込みます。

・前処理

ツイート日時の情報があればいいので、取得したツイートデータのうち created_at 列のみを使います。それでは created_at 列のデータを確認してみましょう。

```
tw_data[["created_at"]][1:10]
```

```
##  [1] "2020-05-24 15:48:56 UTC" "2020-05-24 01:33:57 UTC"
##  [3] "2020-05-23 14:55:20 UTC" "2020-05-23 14:45:54 UTC"
##  [5] "2020-05-23 14:35:50 UTC" "2020-05-23 14:15:49 UTC"
##  [7] "2020-05-23 14:12:26 UTC" "2020-05-23 13:59:04 UTC"
##  [9] "2020-05-23 10:33:35 UTC" "2020-05-23 10:26:21 UTC"
```

取得したツイート日時のタイムゾーンが協定世界時 (UTC) です。これを日本標準時 (JST) に変換にする必要があります。

```
# ツイート日時データを変換
tw_time <- tw_data[["created_at"]] %>% # ツイート日時を抽出
  as.POSIXct(tz = "Etc/GMT") %>% # POSIXct 型の協定世界時を明示
  as.POSIXlt(tz = "Asia/Tokyo") # POSIXlt 型の日本標準時に変換
```

as.POSIXlt() で POSIXct 型から POSIXlt 型に変換します。また tz 引数に"Japan" あるいは"Asia/Tokyo" を指定して、タイムゾーンを日本標準時に変更します。(多分 2 行目はいらない)

変換後のデータを確認しておきましょう。

```
tw_time[1:10]
```

```
##  [1] "2020-05-25 00:48:56 JST" "2020-05-24 10:33:57 JST"
##  [3] "2020-05-23 23:55:20 JST" "2020-05-23 23:45:54 JST"
##  [5] "2020-05-23 23:35:50 JST" "2020-05-23 23:15:49 JST"
##  [7] "2020-05-23 23:12:26 JST" "2020-05-23 22:59:04 JST"
##  [9] "2020-05-23 19:33:35 JST" "2020-05-23 19:26:21 JST"
```

これでツイートデータの取得と前処理は完了です。次からは可視化のための処理を行っていきます。

・年・月・日別に可視化

ここからは、指定した期間 (年・月・日) ごとにツイート数を集計し、棒グラフを作図していきます。

```
# セルの単位（区切る期間）を指定
term <- "year"
term <- "mon"
term <- "day"
```

ツイート数をカウントする際に区切る間隔を指定します。「年」単位であれば year、「月」単位なら mon、「日」単位なら day とします。これは主に floor_date() の unit 引数に指定するためのものなので、このままの文字列を使用してください。

指定した期間ごとのツイートを数を集計します。

```
# 指定した期間ごとにツイート数を集計
tw_count <- tw_time %>%
  floor_date(unit = term) %>% # 指定した単位に切り捨て
  as_date() %>% # Date 型に変換
  tibble(terms = .) %>% # データフレームに変換
  count(terms) # ツイート数をカウント
```

floor_date() で指定した期間ごとに日時を丸め (切り捨て) ます。
また時刻情報も不要なので、as_date() で POSIXlt 型から Date 型に変換することで落とします。
次に tibble() でデータフレームに変換して、count() で各期間のツイート数を集計します。

```
tail(tw_count, 10)
```

```
## # A tibble: 10 x 2
##    terms           n
##    <date>      <int>
##  1 2020-05-15      5
##  2 2020-05-16      3
##  3 2020-05-18      2
##  4 2020-05-19      7
##  5 2020-05-20      4
##  6 2020-05-21      4
##  7 2020-05-22      8
##  8 2020-05-23     20
##  9 2020-05-24      1
## 10 2020-05-25      1
```

このデータフレームを用いて作図します。作図の処理は指定した期間によって異なるため、場合分けしておきます。

```
# 棒グラフを作図
if(term == "day") {

  ggplot(tw_count, aes(x = terms, y = n)) +
    geom_bar(stat = "identity", fill = "#00A968", color = "#00A968") + # 棒グラフ
    scale_x_date(date_breaks = "2 weeks", date_labels = "%Y-%m-%d") + # x 軸目盛（日付）
    theme(axis.text.x = element_text(angle = 90)) + # x 軸目盛の傾き
    labs(title = paste0("@", screen_name, " のツイート数"),
         x = "year-mon-day") # ラベル

} else if(term == "mon") {

  ggplot(tw_count, aes(x = terms, y = n)) +
    geom_bar(stat = "identity", fill = "#00A968") + # 棒グラフ
```

```
    scale_x_date(date_breaks  = "1 month", date_labels = "%Y-%m") + # x軸目盛（日付）
    theme(axis.text.x = element_text(angle = 90)) + # x軸目盛の傾き
    labs(title = paste0("@", screen_name, "のツイート数"),
         x = "year-mon") # ラベル

} else if(term == "year") {

  ggplot(tw_count, aes(x = terms, y = n)) +
    geom_bar(stat = "identity", fill = "#00A968", color = "#00A968") + # 棒グラフ
    scale_x_date(date_breaks = "1 year", date_labels = "%Y") + # x軸目盛（日付）
    labs(title = paste0("@", screen_name, "のツイート数"),
         x = "year") # ラベル

}
```

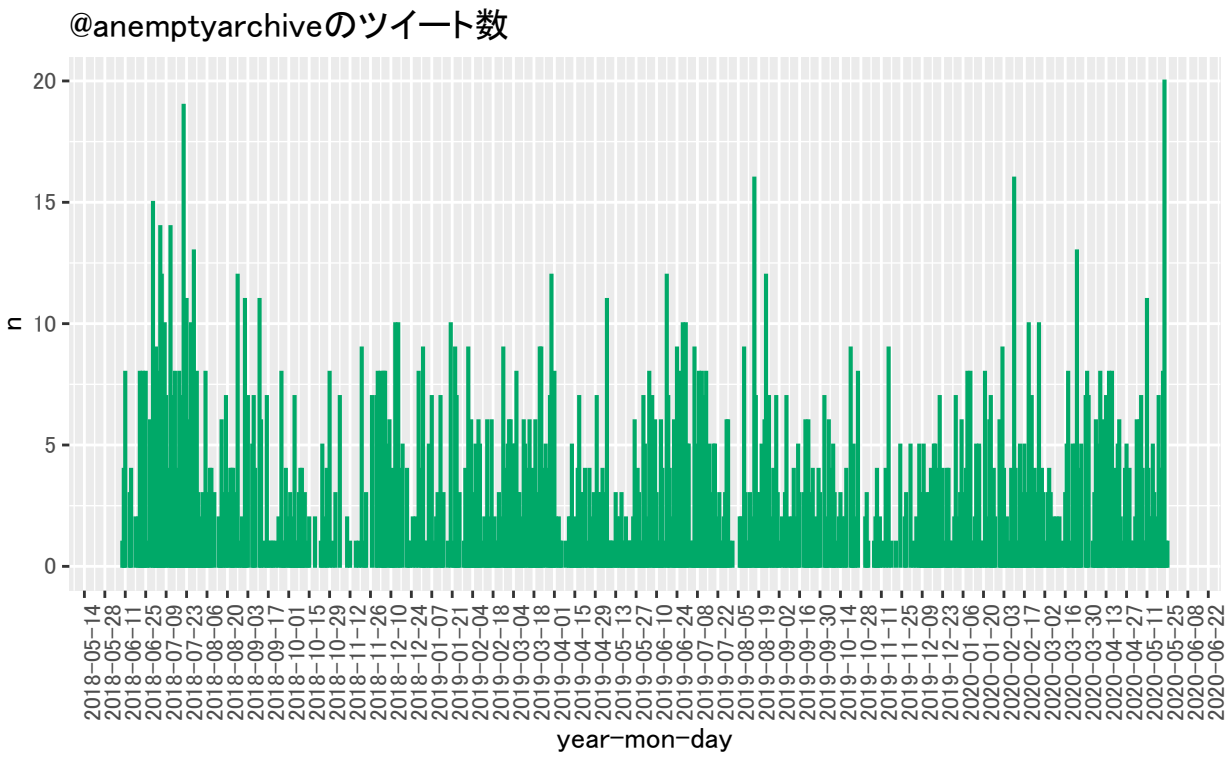

`geom_bar()` で棒グラフを作図します。

x 軸に表示するデータ数が多くなるため、必要に応じて x 軸目盛を表示する位置を間引きます。
Date 型のデータの場合は、`scale_x_date()` で x 軸目盛を調整できます。`date_breaks` 引数に表示する位置を、`date_labels` 引数に表示するテキストの形式を指定します。

・月別

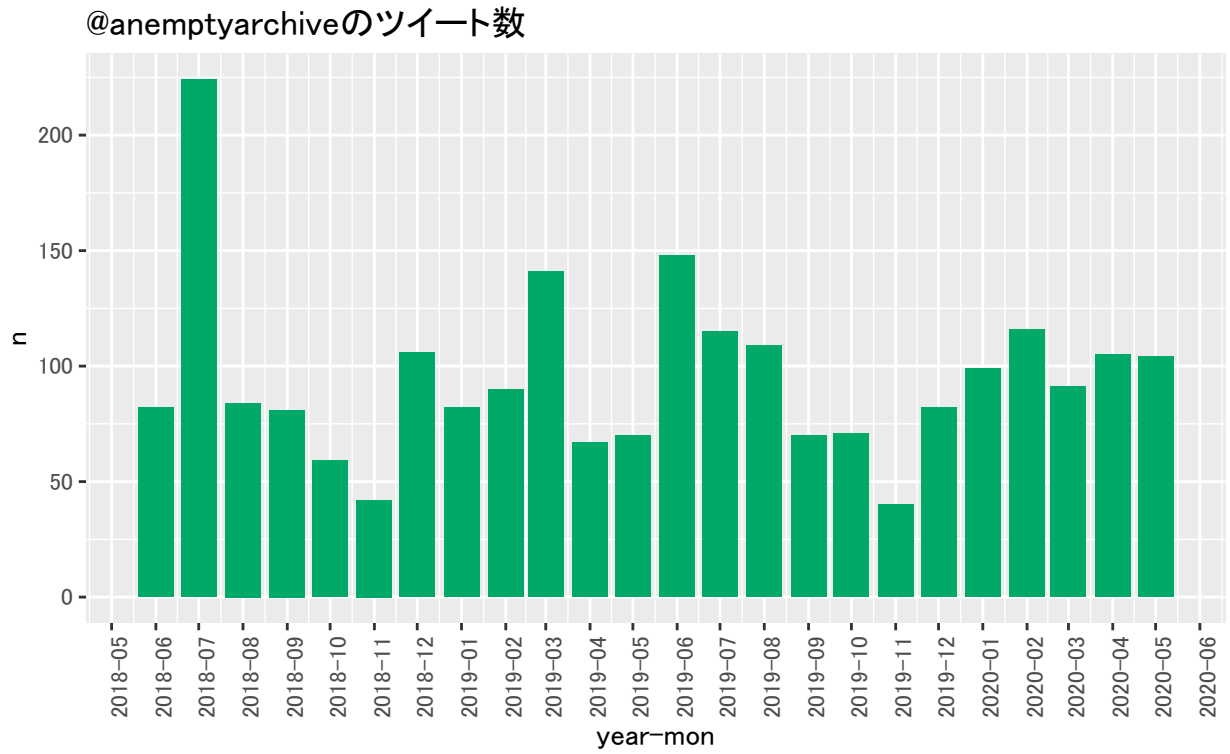
@anemptyarchiveのツイート数
n
200
150
100
50
0
2018-05
2018-06
2018-07
2018-08
2018-09
2018-10
2018-11
2018-12
2019-01
2019-02
2019-03
2019-04
2019-05
2019-06
2019-07
2019-08
2019-09
2019-10
2019-11
2019-12
2020-01
2020-02
2020-03
2020-04
2020-05
2020-06
year-mon

・年別

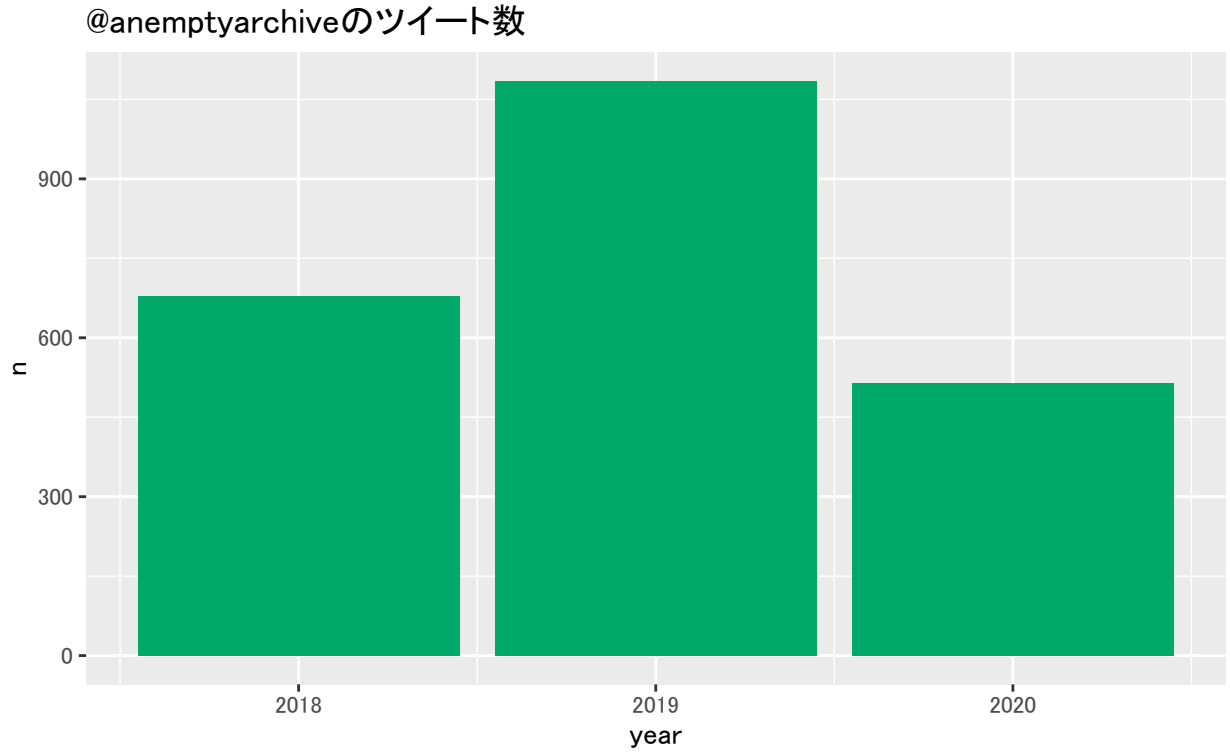
@anemptyarchiveのツイート数
n
900
600
300
0
2018
2019
2020
year

・時別に可視化

続いて、1 時間ごとにツイート数を棒グラフ化します。
基本的な処理は同じです。こちらは可視化に時刻データを用いるため、ツイート日時を POSIXct 型で扱うところが異なります。

```
# セルの単位（区切る期間）を指定
term <- "hour"
```

区分けするときに用いる変数を"hour" としておきます。

```
# 指定した期間ごとにツイート数を集計
tw_count <- tw_time %>%
  floor_date(unit = term) %>% # 指定した単位に切り捨て
  as.POSIXct() %>% # POSIXct 型に変換
  tibble(terms = .) %>% # データフレームに変換
  count(terms) %>% # ツイート数をカウント
  filter(terms >= as.POSIXct("2020-01-01")) %>% # から
  filter(terms <= as.POSIXct("2020-01-31")) # まで
```

floor_date(., unit = "hour") で 1 時間単位で丸めて (切り捨て)、as.POSIXct() で POSIXct 型に戻します。
また tibble() でデータフレームに変換して、count() で各期間のツイート数を集計します。
描画するデータ量が多くなると思われるので、描画する範囲を絞っておきます。

では、完成したデータフレームを確認しておきましょう。

```
tail(tw_count, 10)
```

```
## # A tibble: 10 x 2
##    terms                   n
##    <dttm>              <int>
##  1 2020-01-25 12:00:00     5
##  2 2020-01-25 18:00:00     2
##  3 2020-01-26 17:00:00     1
##  4 2020-01-26 19:00:00     1
##  5 2020-01-27 14:00:00     1
##  6 2020-01-27 16:00:00     1
##  7 2020-01-27 18:00:00     1
##  8 2020-01-27 19:00:00     1
##  9 2020-01-28 12:00:00     1
## 10 2020-01-28 23:00:00     1
```

これを用いて作図します。

```
# 棒グラフを作図
ggplot(tw_count, aes(x = terms, y = n)) +
  geom_bar(stat = "identity", fill = "#00A968", color = "#00A968") + # 棒グラフ
  scale_x_datetime(date_breaks = "12 hours",
                   date_labels = "%Y-%m-%d %H") + # x 軸目盛（日時）
  theme(axis.text.x = element_text(angle = 90)) + # x 軸目盛の傾き
  labs(title = paste0("@", screen_name, " のツイート数"),
       x = "year-mon-day hour") # ラベル
```

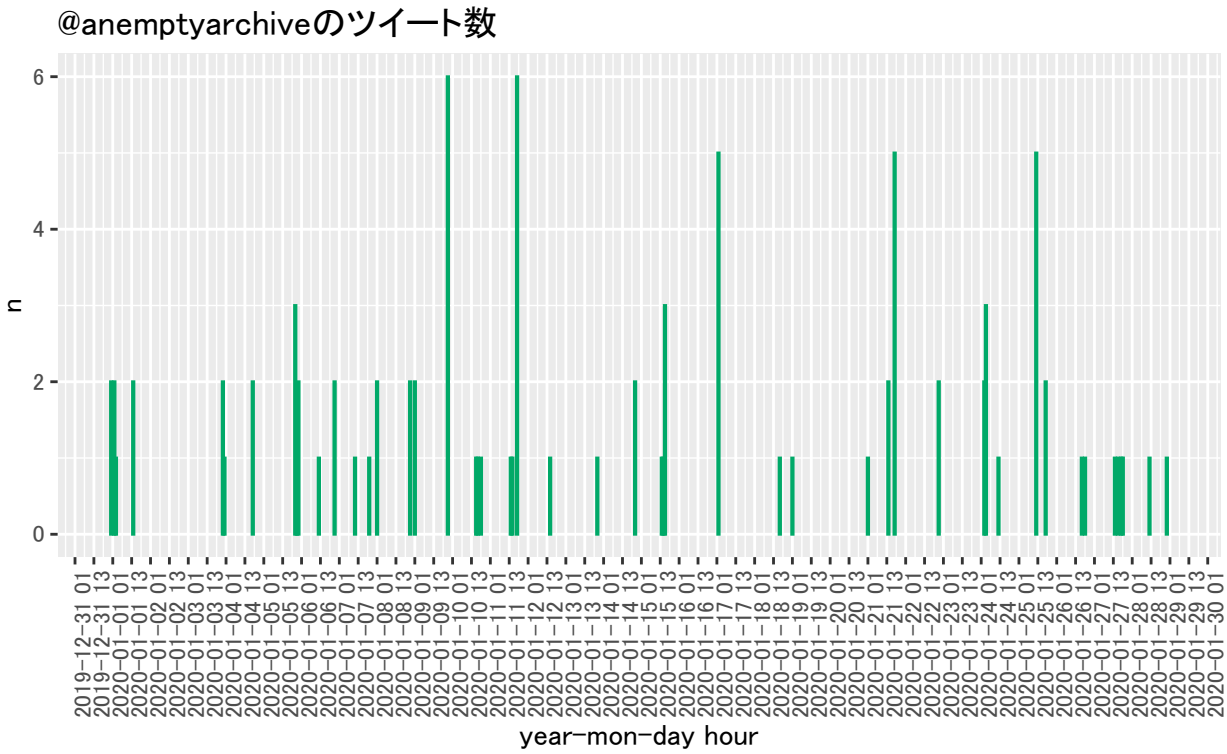

POSIXct 型のデータのときは、scale_x_datetime() で x 軸目盛を調整できます。引数は scale_x_date() と同じく、date_breaks 引数に表示する位置、date_labels 引数に表示するテキストの形式を指定します。

・ツイート数のヒートマップを作成

rtweet パッケージを利用して、指定したアカウントのタイムラインインを収集し、設定した期間 (年・月・日・時) ごとのツイート数を集計し、ヒートマップによる可視化を行います。

```
# 利用パッケージ
library(rtweet) # ツイート収集:get_timeline()
library(dplyr) # データフレーム操作
library(tidyr) # データフレーム操作:replace_na()
library(lubridate) # 時間データ操作:floor_date(), as_date(), now()
library(ggplot2) # 作図
```

利用するパッケージを読み込みます。

・前処理

ツイート数の推移をみるにはツイート日時の情報があればいいので、取得したツイートデータのうち created_at 列のみを使います。それでは created_at 列のデータを確認してみましょう。

```
tw_data[["created_at"]][1:10]
```

```
##  [1] "2020-05-24 15:48:56 UTC" "2020-05-24 01:33:57 UTC"
##  [3] "2020-05-23 14:55:20 UTC" "2020-05-23 14:45:54 UTC"
##  [5] "2020-05-23 14:35:50 UTC" "2020-05-23 14:15:49 UTC"
##  [7] "2020-05-23 14:12:26 UTC" "2020-05-23 13:59:04 UTC"
##  [9] "2020-05-23 10:33:35 UTC" "2020-05-23 10:26:21 UTC"
```

取得したツイート日時のタイムゾーンが協定世界時 (UTC) です。これを日本標準時 (JST) に変換にする必要があります。

```
# ツイート日時データを変換
tw_time <- tw_data[["created_at"]] %>% # ツイート日時を抽出
  as.POSIXct(tz = "Etc/GMT") %>% # POSIXct 型の協定世界時を明示
  as.POSIXlt(tz = "Asia/Tokyo") # POSIXlt 型の日本標準時に変換
```

as.POSIXlt() で POSIXct 型から POSIXlt 型に変換します。また tz 引数に"Japan" あるいは"Asia/Tokyo" を指定して、タイムゾーンを日本標準時に変更します。(多分 2 行目はいらない)

変換後のデータを確認しておきましょう。

```
tw_time[1:10]
```

```
##  [1] "2020-05-25 00:48:56 JST" "2020-05-24 10:33:57 JST"
##  [3] "2020-05-23 23:55:20 JST" "2020-05-23 23:45:54 JST"
##  [5] "2020-05-23 23:35:50 JST" "2020-05-23 23:15:49 JST"
##  [7] "2020-05-23 23:12:26 JST" "2020-05-23 22:59:04 JST"
##  [9] "2020-05-23 19:33:35 JST" "2020-05-23 19:26:21 JST"
```

これでツイートデータの取得と前処理は完了です。次からは可視化のための処理を行っていきます。

・年・月・日別に可視化

ここからは、指定した期間 (年・月・日) ごとにツイート数を集計し、ヒートマップを作図していきます。

```
# セルの単位（区切る期間）を指定
term <- "year"
term <- "mon"
term <- "day"
```

ヒートマップにする際のタイル (セル?) の単位 (期間) を指定します。「年」単位であれば year、「月」単位なら mon、「日」単位なら day とします。これは主に floor_date() の unit 引数に指定するためのものなので、このままの文字列を使用してください。

指定した期間ごとのツイートを数を集計します。

```
# 指定した期間ごとにツイート数を集計
tw_count1 <- tw_time %>%
  floor_date(unit = term) %>% # 指定した期間に切り捨て
  as_date() %>% # Date 型に変換
  tibble(terms = .) %>% # データフレームに変換
  count(terms) # ツイート数をカウント
```

floor_date() で指定した期間ごとに日時を丸めて (切り捨て) ます。
時刻情報も不要なので as_date() で POSIXlt 型から Date 型に変換することで落とします。

次に tibble() でデータフレームに変換して、count() で各期間のツイート数を集計します。

```
tail(tw_count1, 10)
```

```
## # A tibble: 10 x 2
##    terms          n
##    <date>     <int>
##  1 2020-05-15     5
##  2 2020-05-16     3
##  3 2020-05-18     2
##  4 2020-05-19     7
##  5 2020-05-20     4
##  6 2020-05-21     4
##  7 2020-05-22     8
##  8 2020-05-23    20
##  9 2020-05-24     1
## 10 2020-05-25     1
```

このままだと、ツイートがなかったタイミングが (ツイート数 0 ではなく) 抜け落ちてしまいます (5 月 2 日そのものがない)。あとで日時データを文字列型に変換して扱うため、ツイート数 0 の期間としておかないとグラフに表示されません。
その対処として、全ての期間が含まれるデータフレームを作成し、そこにツイート数の情報を移します。

```
# ツイートがない期間が欠落する対策
term_df <- seq(
  floor_date(tail(tw_time, 1), term), # 一番古い日時
  floor_date(now(), term), # 現在日時
  by = term
) %>% # 指定した期間刻みのベクトルを作成
  as_date() %>% # Date 型に変換
  tibble(terms = .)# データフレームに変換

# 集計結果を結合
tw_count2 <- left_join(term_df, tw_count1, by = "terms") %>%
  mutate(n = replace_na(n, 0)) # NA を 0 に置換
```

seq() で、一番古いツイート日時から現在の日時までのベクトルを作ります。このときベクトルの要素は、引数 by 指定した間隔となります。一番古いツイート日時は tw_time の最後の要素なので、tail() または tw_time[length(tw_time)] で取り出して渡します。現在時刻は now() で取得できます。
これを先ほどと同様に、日時データを Date 型に変換し、また全体をデータフレームに変換します。

これを受け皿として、left_join() で先ほどのデータフレームのツイート数と結合します。
このときツイートがなかった期間は NA となるので、それを mutate() と replace_na() を使って 0 に置換します。

集計結果を確認しましょう。

```
tail(tw_count2, 10)
```

```
## # A tibble: 10 x 2
##    terms          n
##    <date>     <dbl>
##  1 2020-05-16     3
##  2 2020-05-17     0
##  3 2020-05-18     2
```

```
##  4 2020-05-19     7
##  5 2020-05-20     4
##  6 2020-05-21     4
##  7 2020-05-22     8
##  8 2020-05-23    20
##  9 2020-05-24     1
## 10 2020-05-25     1
```

5 月 2 日のツイート数が 0 という行が含まれていることが確認できます。

次はこのデータフレームを作図用に加工します。ただし、指定した期間によって処理が多少変わるため、`if()` で場合分けしています。

```
# 軸ラベル用にデータフレームを整形
if(term == "day") {

  tw_count2 <- tw_count2 %>%
    mutate(year_mon = format(terms, "%Y-%m")) %>% # 年月を抽出
    mutate(day = format(terms, "%d")) # 日を抽出

} else if(term == "mon") {

  tw_count2 <- tw_count2 %>%
    mutate(year = format(terms, "%Y")) %>% # 年を抽出
    mutate(mon = format(terms, "%m")) # 月を抽出

} else if(term == "year") {

  tw_count2 <- tw_count2 %>%
    mutate(year = format(terms, "%Y")) # 年を抽出

}
```

指定した期間を y 軸ラベル、それより大きな単位を x 軸目盛とするために、それぞれ `format()` でツイート日の列 (`terms`) から必要な情報を取り出し、`mutate()` で新しい列とします。

作図用のデータフレームができたので、これを用いて作図します。作図の処理も指定した期間によって異なるため、場合分けします。

```
# ヒートマップを作図
if(term == "day") {

  ggplot(tw_count2, aes(x = year_mon, y = day, fill = n)) +
    geom_tile() + # ヒートマップ
    scale_fill_gradient(low = "white" , high = "#00A968") + # 塗りつぶしの濃淡
    theme(axis.text.x = element_text(angle = 90, hjust = 1)) + # 軸目盛の傾き
    labs(title = paste0("@", screen_name, " のツイート数"),
         x = "year-mon", y = "day") # ラベル

} else if(term == "mon") {

  ggplot(tw_count2, aes(x = year, y = mon, fill = n)) +
    geom_tile() + # ヒートマップ
    scale_fill_gradient(low = "white" , high = "#00A968") + # 塗りつぶしの濃淡
```

```
    labs(title = paste0("@", screen_name, " のツイート数"),
         x = "year", y = "mon") # ラベル

} else if(term == "year") {

  ggplot(tw_count2, aes(x = year, y = 0, fill = n)) +
    geom_tile() + # ヒートマップ
    scale_fill_gradient(low = "white" , high = "#00A968") + # 塗りつぶしの濃淡
    ylim(c(-1, 1)) + # y軸の範囲
    labs(title = paste0("@", screen_name, " のツイート数"),
         x = "year", y = "") # ラベル

}
```

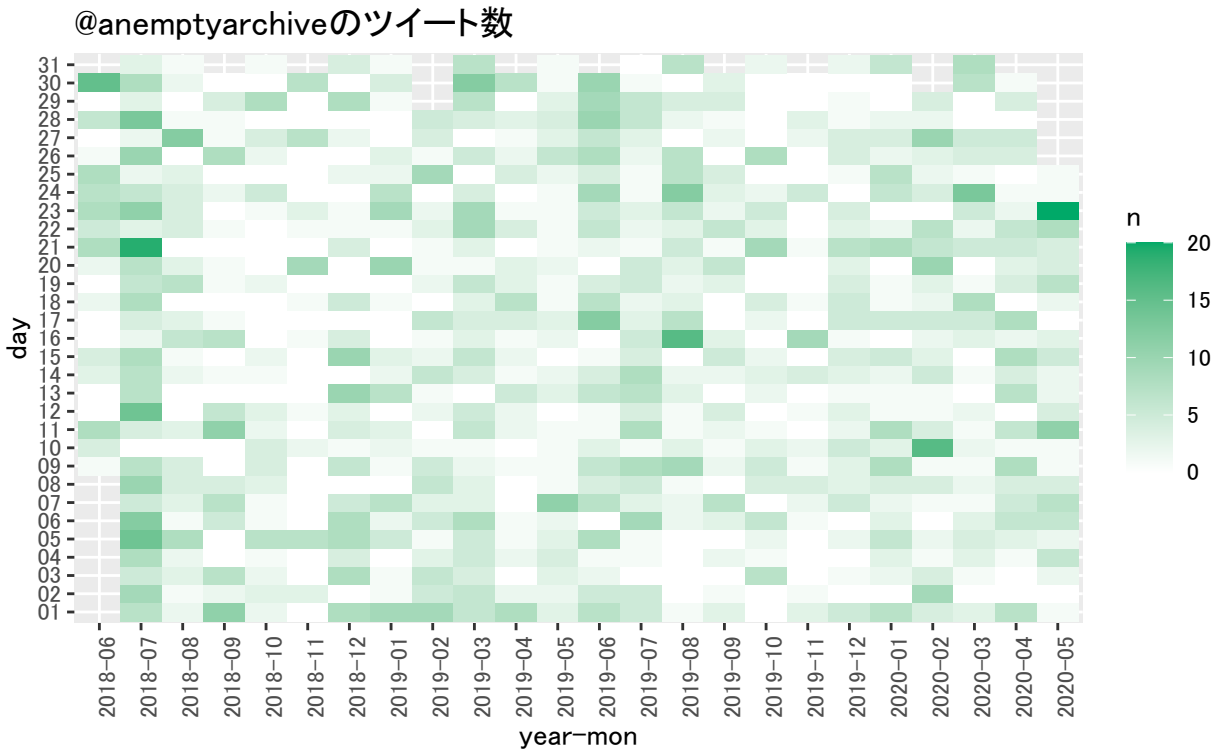

geom_tile() でヒートマップを作図します。
タイルの色は scale_fill_gradient() の low と high にそれぞれ色を指定することで、ツイート数 (fill 引数の値) に応じたグラデーションとなります。

・月ごとの場合

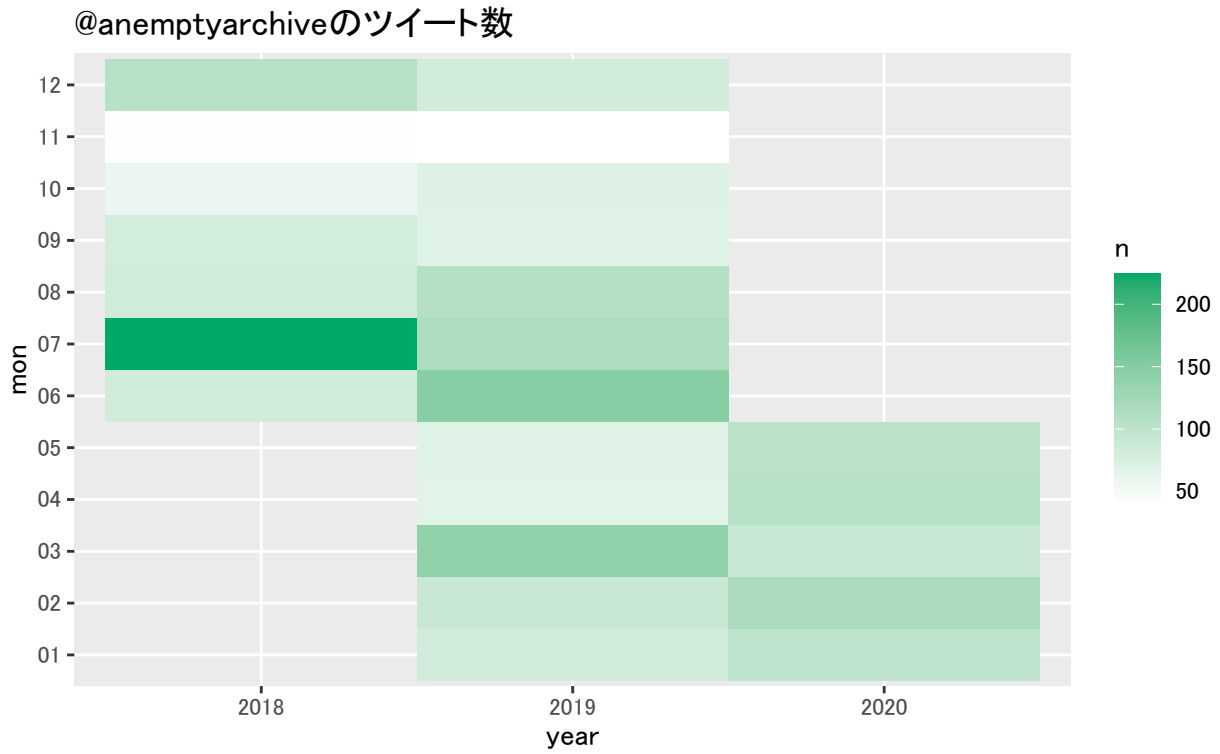
@anemptyarchiveのツイート数
mon
12
11
10
09
08
07
06
05
04
03
02
01
2018
2019
2020
year
n
200
150
100
50

・年ごとの場合

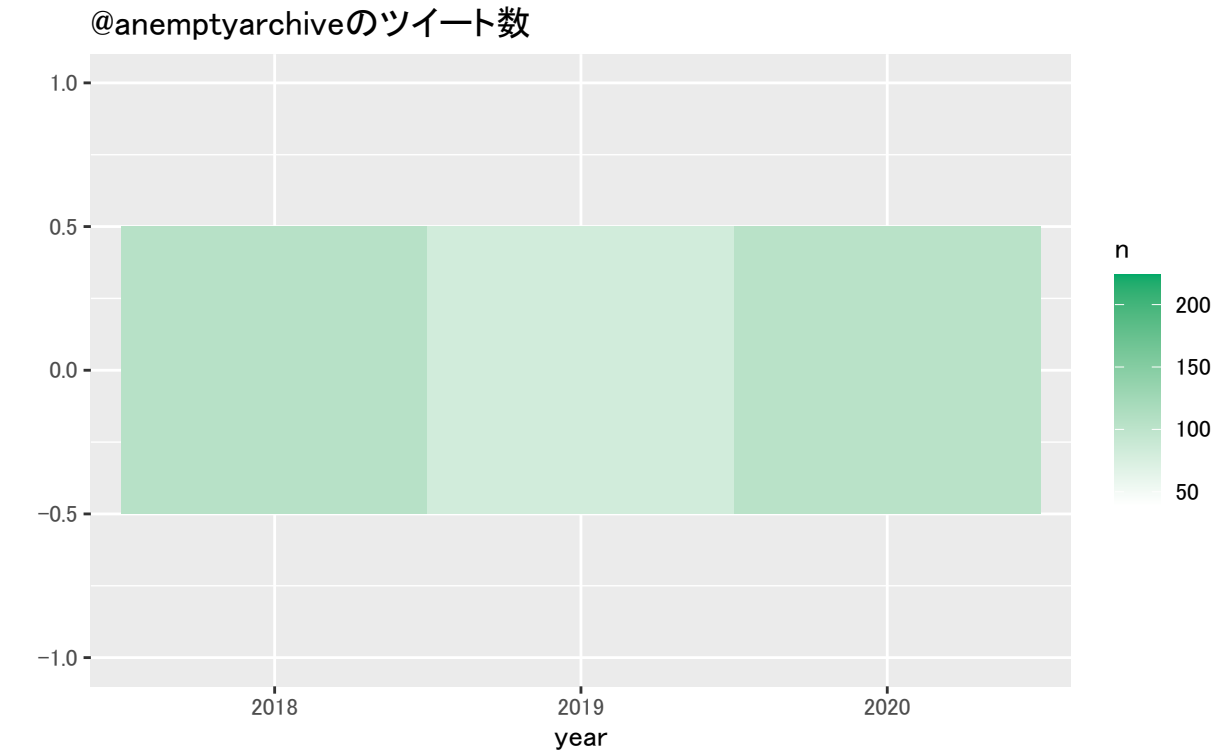
@anemptyarchiveのツイート数
1.0
0.5
0.0
−0.5
−1.0
2018
2019
2020
year
n
200
150
100
50

・時別に可視化

続いて、1 時間ごとのツイート数をヒートマップ化します。
基本的な処理は同様です。こちらは可視化に時刻データを用いるため、ツイート日時を POSIXct 型で扱うところが異なります。

```
# 1 時間ごとにツイート数を集計
tw_count1 <- tw_time %>%
  floor_date(unit = "hour") %>% # 1 時間単位で切り捨て
  as.POSIXct() %>% # POSIXct 型に変換
  tibble(terms = .) %>% # データフレームに変換
  count(terms) # ツイート数をカウント

# ツイートがない期間が欠落する対策
term_df <- seq(
  floor_date(tw_time[length(tw_time)], "hour"), # 一番古い時刻
  floor_date(now(), "hour"), # 現在時刻
  by = "hour"
) %>% # 1 時間刻みのベクトルを作成
  tibble(terms = .) # データフレームに変換

# 作図用にデータフレームを加工
tw_count2 <- left_join(term_df, tw_count1, by = "terms") %>% # 集計結果を結合
  mutate(n = replace_na(n, 0)) %>%  # NA を 0 に置換
  mutate(year_mon_day = as_date(terms)) %>% # 年月日を抽出
  mutate(hour = format(terms, "%H")) # 時間を抽出
```

floor_date(., unit = "hour") で 1 時間単位で丸めて (切り捨て)、as.POSIXct() で POSIXct 型に変換します。
また tibble() でデータフレームに変換して、count() で各期間のツイート数を集計します。

期間内にツイートがなかった場合に欠落する問題の対処や、作図用のデータフレームの加工も概ね同じ流れです。

期間を指定する際に"hour" とする点に注意しましょう。

では、完成したデータフレームを確認しておきましょう。

```
tail(tw_count2, 10)
```

```
## # A tibble: 10 x 4
##    terms                  n year_mon_day hour
##    <dttm>             <dbl> <date>       <chr>
##  1 2020-05-25 07:00:00     0 2020-05-25   07
##  2 2020-05-25 08:00:00     0 2020-05-25   08
##  3 2020-05-25 09:00:00     0 2020-05-25   09
##  4 2020-05-25 10:00:00     0 2020-05-25   10
##  5 2020-05-25 11:00:00     0 2020-05-25   11
##  6 2020-05-25 12:00:00     0 2020-05-25   12
##  7 2020-05-25 13:00:00     0 2020-05-25   13
##  8 2020-05-25 14:00:00     0 2020-05-25   14
##  9 2020-05-25 15:00:00     0 2020-05-25   15
## 10 2020-05-25 16:00:00     0 2020-05-25   16
```

これを用いて作図します。

```
# ヒートマップを作図
ggplot(tw_count2, aes(x = year_mon_day, y = hour, fill = n)) +
  geom_tile() + # ヒートマップ
  scale_fill_gradient(low = "white", high = "#00A968") + # 塗りつぶしの濃淡
  scale_x_date(breaks = seq(tw_count2[["year_mon_day"]][1],
                            tw_count2[["year_mon_day"]][nrow(tw_count2)],
                            by = "1 week")) + # x軸目盛（日付）
  theme(axis.text.x = element_text(angle = 90)) + # x軸目盛の傾き
  labs(title = paste0("@", screen_name, "のツイート数"),
       x = "year-mon-day", y = "hour") # ラベル
```

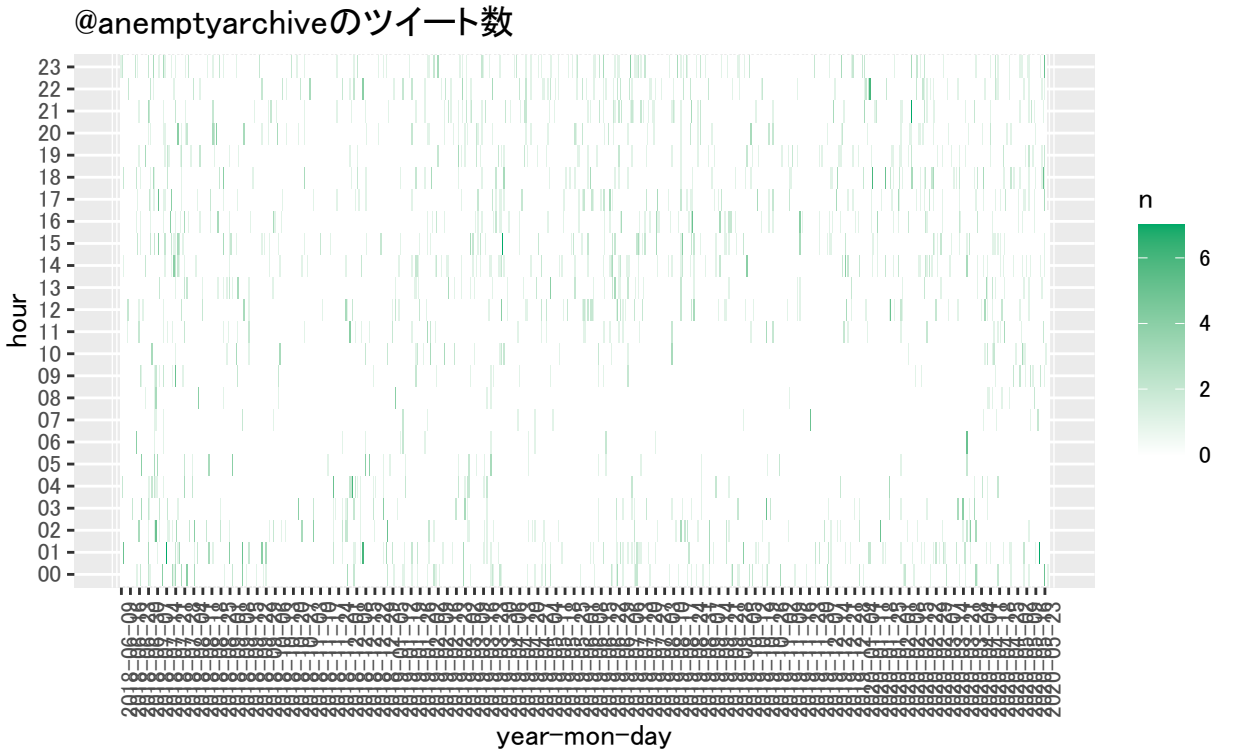

x 軸に表示するデータ数が多くなるため、必要に応じて scale_x_date() で、x 軸ラベルを表示する位置を間引きます (ここに表示されるラベルデータは文字列型なので自動調整されない)。 scale_x_date() の breaks 引数に、表示する位置のベクトルを渡すことで表示数を絞ることができます。そのベクトルは、seq() に tw_count2 の year_mon_day 列の 1 行目と最終行の要素を渡して作成します。by 引数に指定する間隔を変更して調整してください。